

Clase 17. Matrices Ortogonales y el Proceso de Gram-Schmidt.

Curso ‘Linear Algebra’ del MIT.

Resumen

La clase pasada terminamos estudiando preliminarmente los **vectores ortonormales**. En esta ocasión nos concentraremos en ellos y en las **matrices ortogonales**, viendo sus características y cómo obtenerlas cuando, inicialmente, dichos objetos no son perpendiculares. Para esto último, usaremos el **Proceso de Gram-Schmidt**.

1. Vectores Ortonormales.

La clase anterior señalamos que los **vectores ortonormales** son aquellos que se caracterizan por ser:

- Ortogonales entre sí.
- Vectores Unitarios (i.e, de magnitud igual a 1).

Formalmente se indica que dos (o más) vectores \vec{q}_i y \vec{q}_j son **ortonormales** si:

$$\vec{q}_i^T \cdot \vec{q}_j = \begin{cases} 0 & \text{cuando } i \neq j \\ 1 & \text{cuando } i = j \end{cases}$$

La primera condición es la de ortogonalidad. Recordemos que dos vectores de igual dimensionalidad, pero de componentes distintos, son perpendiculares si en su producto punto:

$$\vec{q}_i^T \cdot \vec{q}_j = 0 \text{ (con } i \neq j)$$

Mientras que la segunda condición hace referencia a que sean unitarios y también se puede explicar a partir de su producto punto. Como ya hemos estudiado, el producto punto entre

un vector y sí mismo coincide con ser su magnitud al cuadrado.

$$\vec{q}_i^T \cdot \vec{q}_j = \|\vec{q}\|^2 \text{ (con } i = j\text{)}$$

Si $\|\vec{q}\| = 1$ (i.e, si \vec{q} es unitario), entonces:

$$\vec{q}_i^T \cdot \vec{q}_j = 1 \text{ (con } i = j\text{)}$$

Los **vectores unitarios** también reciben el nombre de **vectores normalizados** y son aquellos de **magnitud 1** que **van en la misma dirección de otro vector**, los cuales se obtienen multiplicando a este último por el recíproco de su magnitud.

Por ejemplo, sea $\vec{a} \neq \vec{0}$. Su versión normalizada \hat{a} se calcula como:

$$\hat{a} = \frac{1}{\|\vec{a}\|} \cdot \vec{a}$$

La **norma** (o norma vectorial) es otra forma de referirnos a la magnitud de un vector.

De este modo, ahora podemos entender por qué los vectores **ortonormales** se llaman así:

- Orto \rightarrow Perpendiculares (u ortogonales).
- Normal \rightarrow Unitarios.

Un conjunto de vectores ortonormales, al ser ortogonales, siempre son **linealmente independientes** entre sí. A continuación se demuestra esta afirmación.

Demostración. Sean $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$ vectores ortogonales distinto de $\vec{0}$ y c_1, c_2, \dots, c_n valores escalares. Estos vectores son linealmente independientes si:

$$\sum_{i=1}^n c_i \vec{v}_i = \vec{0} \iff c_1, c_2, \dots, c_n = 0$$

Calculemos el producto punto en la igualdad de arriba con la transpuesta del vector ortogonal $\vec{v}_i \neq \vec{0}$ para cada $i = 1, 2, \dots, n$:

$$\begin{aligned} \vec{v}_i^T \cdot \sum_{i=1}^n c_i \vec{v}_i &= \vec{v}_i^T \cdot \vec{0} \\ \vec{v}_i^T \cdot (c_1 \vec{v}_1 + c_2 \vec{v}_2 + \dots + c_n \vec{v}_n) &= 0 \\ c_1(\vec{v}_i^T \vec{v}_1) + c_2(\vec{v}_i^T \vec{v}_2) + \dots + c_n(\vec{v}_i^T \vec{v}_n) &= 0 \end{aligned}$$

Cada vez que $i \neq j$, con $j = 1, 2, \dots, n$, $\vec{v}_i^T \cdot \vec{v}_j = 0$. Por lo tanto, cuando $i = j$:

$$c_i \|\vec{v}_i\|^2 = 0$$

Como $\vec{v}_i \neq \vec{0}$, entonces $\|\vec{v}_i\| \neq 0$, por lo que la única posibilidad de que $c_i \|\vec{v}_i\|^2 = 0$, es que $c_i = 0$.

En consecuencia, se demuestra que los vectores ortogonales $\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n$ **son linealmente independientes** porque su combinación lineal puede ser igual a $\vec{0}$ solo cuando $c_1, c_2, \dots, c_n = 0$.

En ese sentido, como los **vectores ortonormales** son ortogonales, entonces también son **linealmente independientes** y el conjunto de ellos forma una **base** (*basis*).

2. Matrices Ortogonales.

Con una base ortonormal podemos formar una matriz que suele denotarse como Q , donde los primeros son los vectores columna de esta última.

La principal característica de una matriz Q , es que satisface la siguiente igualdad:

$$Q^T Q = I$$

Demostración. Sean $\vec{q}_1, \vec{q}_2, \dots, \vec{q}_m$ vectores columna ortonormales de Q en \mathbb{R}^n . Entonces:

$$Q^T Q = I$$

$$\begin{bmatrix} \vec{q}_1^T \\ \vec{q}_2^T \\ \vdots \\ \vec{q}_m^T \end{bmatrix} \cdot \begin{bmatrix} \vec{q}_1 & \vec{q}_2 & \cdots & \vec{q}_m \end{bmatrix} = I$$

$$\begin{bmatrix} (\vec{q}_1^T \cdot \vec{q}_1) & (\vec{q}_1^T \cdot \vec{q}_2) & \cdots & (\vec{q}_1^T \cdot \vec{q}_m) \\ (\vec{q}_2^T \cdot \vec{q}_1) & (\vec{q}_2^T \cdot \vec{q}_2) & \cdots & (\vec{q}_2^T \cdot \vec{q}_m) \\ \vdots & \vdots & \ddots & \vdots \\ (\vec{q}_m^T \cdot \vec{q}_1) & (\vec{q}_m^T \cdot \vec{q}_2) & \cdots & (\vec{q}_m^T \cdot \vec{q}_m) \end{bmatrix} = I$$

Recordemos que:

$$\vec{q}_i^T \cdot \vec{q}_j = \begin{cases} 0 & \text{cuando } i \neq j \\ 1 & \text{cuando } i = j \end{cases}$$

donde \vec{q}_i y \vec{q}_j son ortonormales. Por lo tanto:

$$\begin{bmatrix} (\vec{q}_1^T \cdot \vec{q}_1) & (\vec{q}_1^T \cdot \vec{q}_2) & \cdots & (\vec{q}_1^T \cdot \vec{q}_m) \\ (\vec{q}_2^T \cdot \vec{q}_1) & (\vec{q}_2^T \cdot \vec{q}_2) & \cdots & (\vec{q}_2^T \cdot \vec{q}_m) \\ \vdots & \vdots & \ddots & \vdots \\ (\vec{q}_m^T \cdot \vec{q}_1) & (\vec{q}_m^T \cdot \vec{q}_2) & \cdots & (\vec{q}_m^T \cdot \vec{q}_m) \end{bmatrix} = I$$

$$\begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = I$$

La diagonal de $Q^T Q$ serán solo 1s y el resto de sus entradas, ceros. Así, $Q^T Q = I$ (Q.E.D).

Ahora bien, la igualdad $Q^T Q = I$ se cumple solo si en Q de $n \times m$, $n \geq m$. En cambio, si $n \leq m$, solo se satisface $Q Q^T = I$. No obstante, cuando $n = m$, ocurre que:

$$Q^T Q = Q Q^T = I$$

La igualdad de arriba es el **criterio de invertibilidad** que estudiamos en la Clase 3: Si una matriz A es **cuadrada e invertible**, se satisface que:

$$A^{-1} A = A A^{-1} = I$$

En otras palabras, cuando Q es cuadrada (i.e, $n = m$), se cumple que $Q^T = Q^{-1}$ y, por consiguiente, que:

$$Q^{-1} Q = Q Q^{-1} = I$$

En ese momento, Q recibe el nombre de **Matriz Ortogonal**, la cual se caracteriza por:

- Tener vectores columna **ortonormales**.
- Ser cuadrada.
- Ser invertible, donde $Q^{-1} = Q^T$.

2.1 Ejemplos de Matrices Ortogonales.

Una **matriz permutación** cuadrada es un ejemplo de una matriz ortogonal. Como recordaremos, consiste de ceros y un 1 en cada columna, la cual se usa para reordenar las entradas de otra matriz al multiplicarla. A continuación tenemos un ejemplo:

Sea P la siguiente matriz permutación:

$$P = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

Los vectores columna de P son ortogonales entre sí y todos de magnitud igual a 1. Ahora multipliquémosle su transpuesta.

$$P^T P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = I$$

Otro ejemplo de una matriz ortogonal es la **Matriz de Rotación** R , la cual es utilizada para hacer rotar un objeto en un espacio euclidiano:

$$R = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}$$

Las columnas de R son ortogonales y unitarias. Además, cuando es multiplicada por su transpuesta, obtenemos la matriz identidad:

$$R^T R = \begin{bmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{bmatrix} \cdot \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I$$

En ocasiones nos encontraremos con matrices de columnas ortogonales, pero que no son unitarias. Un ejemplo son las **Matrices Hadamard** H . Éstas son cuadradas, con entradas de valores 1 y -1 y sus columnas son perpendiculares entre sí. A continuación tenemos una de 4×4 :

$$H = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}$$

Veamos que todas las columnas de H son de magnitud 2. Por lo tanto, podemos normalizarlas multiplicando a esta matriz por $1/2$ (i.e, el recíproco de sus normas), pasando a ser **ortonormales** y, en consecuencia, $H = Q$.

$$\frac{1}{2} \cdot H = \frac{1}{2} \cdot \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix} = \begin{bmatrix} 0.5 & 0.5 & 0.5 & 0.5 \\ 0.5 & -0.5 & 0.5 & -0.5 \\ 0.5 & 0.5 & -0.5 & -0.5 \\ 0.5 & -0.5 & -0.5 & 0.5 \end{bmatrix} = Q$$

Al ser cuadrada, se cumplirá que $Q^T Q = I$.

2.2 Aplicación de las Matrices Ortogonales.

Las matrices ortogonales son útiles, por ejemplo, para **buscar una matriz de proyección**.

Como recordaremos de la Clase 15, la matriz de proyección P para buscar a un vector $\vec{p} \in C(A)$ que se proyecte sobre $\vec{b} \notin C(A)$, se obtiene a partir de la siguiente fórmula:

$$P = A(A^T A)^{-1} A^T$$

conllevando a que:

$$\vec{p} = P\vec{b}$$

En ciertas ocasiones podría ser más preferible trabajar con una matriz Q de vectores columna ortonormales y, por consiguiente, buscar a $\vec{p} \in C(Q)$ proyectado sobre \vec{b} :

$$P = Q(Q^T Q)^{-1} Q^T$$

Como las columnas de Q son ortonormales, entonces son linealmente independientes y podemos dar por asegurado al menos que $Q^T Q = I$:

$$P = Q(I)^{-1} Q^T = Q I Q^T = Q Q^T$$

En ese sentido, si Q es cuadrada, entonces:

$$P = I$$

Esta última igualdad hace sentido, puesto que si Q es cuadrada y sus columnas linealmente independientes¹, \vec{b} estará sí o sí en $C(Q)$, de manera que:

$$\vec{p} = I\vec{b} = \vec{b}$$

¹Y, por consiguiente, de rango completo.

Por lo tanto, para Q de $n \times m$ podemos resumir que:

$$P = \begin{cases} I & \text{si } n = m \\ QQ^T & \text{si } n > m \end{cases}$$

Las propiedades de P , $P^2 = P$ y $P^T = P$, también se aplican en QQ^T :

$$(QQ^T)^2 = (QQ^T) \cdot (QQ^T) = Q(Q^T Q)Q^T = QIQ^T = QQ^T$$

$$(QQ^T)^T = (Q^T)^T Q^T = QQ^T$$

También se hace más fácil resolver las **ecuaciones normales del método de mínimos cuadrados** usando matrices ortogonales.

En el método de mínimos cuadrados, como estudiamos en la Clase 16, las ecuaciones normales se obtienen como:

$$A^T A \hat{x} = A^T \vec{b}$$

donde \hat{x} es el vector de las mejores soluciones del sistema $A\vec{x} = \vec{b}$ cuando no tiene soluciones.

Si, en vez de trabajar con una matriz A , lo hacemos con una Q de vectores columna ortonormales, entonces:

$$Q^T Q \hat{x} = Q^T \vec{b}$$

$$I \hat{x} = Q^T \vec{b}$$

$$\hat{x} = Q^T \vec{b}$$

Por lo tanto, sean \hat{x}_i los componentes del vector \hat{x} , para $i = 1, 2, \dots, n$; y \vec{q}_j los vectores columnas ortogonales de Q , donde $j = 1, 2, \dots, m$, los primeros corresponderán a:

$$\hat{x}_i = \vec{q}_i^T \cdot \vec{b}$$

3. Proceso de Gram-Schmidt.

Cuando tenemos un conjunto de **vectores linealmente independientes**, es posible **ortonormalizarlos** a través de un algoritmo llamado **Proceso de Gram-Schmidt**.

Digamos que el conjunto $X = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_m\}$ son vectores linealmente independientes; los de $U = \{\vec{u}_1, \vec{u}_2, \dots, \vec{u}_m\}$ son ortogonales; y los de $W = \{\vec{w}_1, \vec{w}_2, \dots, \vec{w}_m\}$, ortonormales.

La tarea del proceso de Gram-Schmidt es convertir a los vectores de X en los de U y luego

en los de W , pero la condición es que los primeros sean linealmente independientes.

Paso 1. El primer paso del proceso de Gram-Schmidt, es establecer que

$$\vec{u}_1 = \vec{x}_1$$

y luego normalizamos a \vec{u}_1 para obtener a la versión ortonormalizada de \vec{x}_1 , \vec{w}_1 .

$$\vec{w}_1 = \frac{1}{\|\vec{u}_1\|} \cdot \vec{u}_1$$

Paso 2. Ahora debemos buscar a \vec{w}_2 a partir de \vec{x}_2 , tal que $\vec{w}_1 \perp \vec{w}_2$. Para ello, definimos a \vec{u}_2 como la resta entre \vec{x}_2 y la proyección de este último sobre \vec{u}_1 .

$$\vec{u}_2 = \vec{x}_2 - \left(\vec{u}_1 \cdot \frac{\vec{u}_1^T \vec{x}_2}{\vec{u}_1^T \vec{u}_1} \right)$$

El vector \vec{u}_2 es, básicamente, el vector error que estudiamos en la Clase 15.

Ahora, veamos que la proyección de \vec{x}_1 sobre \vec{u}_1 la podemos simplificar de la siguiente manera:

$$\vec{u}_1 \cdot \frac{\vec{u}_1^T \vec{x}_2}{\vec{u}_1^T \vec{u}_1} = \frac{\vec{u}_1 \cdot \vec{u}_1^T}{\|\vec{u}_1\|^2} \cdot \vec{x}_2 = \frac{\vec{u}_1}{\|\vec{u}_1\|} \cdot \frac{\vec{u}_1^T}{\|\vec{u}_1\|} \cdot \vec{x}_2$$

Recordemos que $(1/\|\vec{u}_1\|) \cdot \vec{u}_1 = \vec{w}_1$. Por lo tanto:

$$\vec{u}_1 \cdot \frac{\vec{u}_1^T \vec{x}_2}{\vec{u}_1^T \vec{u}_1} = \vec{w}_1 \cdot (\vec{w}_1^T \cdot \vec{x}_2)$$

De este modo, encontramos una forma más sencilla de calcular a \vec{u}_2 :

$$\vec{u}_2 = \vec{x}_2 - (\vec{w}_1^T \cdot \vec{x}_2) \cdot \vec{w}_1$$

Posteriormente, normalizamos a \vec{u}_2 .

$$\vec{w}_2 = \frac{1}{\|\vec{u}_2\|} \cdot \vec{u}_2$$

Paso 3. Continuamos con \vec{w}_3 , donde $\vec{w}_3 \perp \vec{w}_1$ y $\vec{w}_3 \perp \vec{w}_2$. Primero buscamos a \vec{u}_3 como la resta entre \vec{x}_3 y las proyecciones de este vector sobre \vec{u}_1 y sobre \vec{u}_2 .

$$\vec{u}_3 = \vec{x}_3 - (\vec{w}_1^T \cdot \vec{x}_3) \cdot \vec{w}_1 - (\vec{w}_2^T \cdot \vec{x}_3) \cdot \vec{w}_2$$

para después normalizarlo, resultando en \vec{w}_3 :

$$\vec{w}_3 = \frac{1}{\|\vec{u}_3\|} \cdot \vec{u}_3$$

Así, podemos resumir el proceso de Gram-Schmidt para los m vectores de W como:

$$\begin{aligned} \vec{u}_1 &= \vec{x}_1, & \vec{w}_1 &= \frac{1}{\|\vec{u}_1\|} \cdot \vec{u}_1 \\ \vec{u}_2 &= \vec{x}_2 - (\vec{w}_1^T \cdot \vec{x}_2) \cdot \vec{w}_1, & \vec{w}_2 &= \frac{1}{\|\vec{u}_2\|} \cdot \vec{u}_2 \\ \vec{u}_3 &= \vec{x}_3 - (\vec{w}_1^T \cdot \vec{x}_3) \cdot \vec{w}_1 - (\vec{w}_2^T \cdot \vec{x}_3) \cdot \vec{w}_2, & \vec{w}_3 &= \frac{1}{\|\vec{u}_3\|} \cdot \vec{u}_3 \\ \vec{u}_4 &= \vec{x}_4 - (\vec{w}_1^T \cdot \vec{x}_4) \cdot \vec{w}_1 - (\vec{w}_2^T \cdot \vec{x}_4) \cdot \vec{w}_2 - (\vec{w}_3^T \cdot \vec{x}_4) \cdot \vec{w}_3, & \vec{w}_4 &= \frac{1}{\|\vec{u}_4\|} \cdot \vec{u}_4 \\ &\vdots & &\vdots \\ \vec{u}_m &= \vec{x}_m - \sum_{i=1}^{m-1} (\vec{w}_i^T \cdot \vec{x}_m) \cdot \vec{w}_i, & \vec{w}_m &= \frac{1}{\|\vec{u}_m\|} \cdot \vec{u}_m \end{aligned}$$

4. Descomposición $A = QR$.

Continuemos con los conjuntos de vectores X , U y W usados en la sección anterior.

Una consecuencia del Proceso de Gram-Schmidt, es que cada vector de X es una combinación lineal de los de W y viceversa. Esto significa² que:

$$\text{span}(X) = \text{span}(W)$$

Recordemos que:

$$\vec{w}_1 = \frac{1}{\|\vec{u}_1\|} \cdot \vec{u}_1$$

Si despejamos \vec{u}_1 , entonces:

$$\vec{u}_1 = \|\vec{u}_1\| \cdot \vec{w}_1$$

Y como $\vec{u}_1 = \vec{x}_1$:

$$\vec{x}_1 = \|\vec{u}_1\| \cdot \vec{w}_1$$

²Anton y Rorres (2013). *Elementary Linear Algebra. Applications Version*. Pp. 200.

Del mismo modo, como $\vec{w}_2 = (1/||\vec{u}_2||) \cdot \vec{u}_2$, entonces:

$$\vec{u}_2 = ||\vec{u}_2|| \cdot \vec{w}_2$$

Si reemplazamos a \vec{u}_2 en la ecuación $\vec{u}_2 = \vec{x}_2 - (\vec{w}_1^T \cdot \vec{x}_2) \cdot \vec{w}_1$ y despejamos \vec{x}_2 en ella, entonces:

$$\vec{x}_2 = (\vec{w}_1^T \cdot \vec{x}_2) \cdot \vec{w}_1 + ||\vec{u}_2|| \cdot \vec{w}_2$$

En otras palabras:

$$\begin{aligned}\vec{x}_1 &= ||\vec{u}_1|| \cdot \vec{w}_1 \\ \vec{x}_2 &= (\vec{w}_1^T \cdot \vec{x}_2) \cdot \vec{w}_1 + ||\vec{u}_2|| \cdot \vec{w}_2 \\ \vec{x}_3 &= (\vec{w}_1^T \cdot \vec{x}_3) \cdot \vec{w}_1 + (\vec{w}_2^T \cdot \vec{x}_3) \cdot \vec{w}_2 + ||\vec{u}_3|| \cdot \vec{w}_3 \\ &\vdots \\ \vec{x}_m &= \sum_{i=1}^{m-1} [(\vec{w}_i^T \cdot \vec{x}_m) \cdot \vec{w}_i] + ||\vec{u}_m|| \cdot \vec{w}_m\end{aligned}$$

donde $(\vec{w}_i^T \cdot \vec{x}_m)$ y $||\vec{u}_m||$ son **escalares**.

Veamos esta idea en matrices. Digamos que A es una matriz de $n \times m$ con columnas linealmente independientes, o de $\text{rango}(A) = m$, y las ortonormalizamos usando el proceso de Gram-Schmidt, obteniendo a Q también de $n \times m$ y de $\text{rango}(Q) = m$.

Sea $A = [\vec{a}_1 \ \vec{a}_2 \ \cdots \ \vec{a}_m]$, sabemos que coincide que $\text{span}(\vec{a}_1, \vec{a}_2, \cdots, \vec{a}_m) = C(A)$. De igual modo, si $Q = [\vec{q}_1 \ \vec{q}_2 \ \cdots \ \vec{q}_m]$, entonces $\text{span}(\vec{q}_1, \vec{q}_2, \cdots, \vec{q}_m) = C(Q)$. Por lo tanto, a partir de lo que estudiamos anteriormente:

$$C(A) = C(Q)$$

Es decir, cada vector columna de A es una combinación lineal de los Q .

Supongamos que U es una matriz que consiste de las columnas ortogonalizadas de A . Que $C(A) = C(Q)$ significa que:

$$\begin{aligned}\vec{a}_1 &= ||\vec{u}_1|| \cdot \vec{q}_1 \\ \vec{a}_2 &= (\vec{q}_1^T \cdot \vec{a}_2) \cdot \vec{q}_1 + ||\vec{u}_2|| \cdot \vec{q}_2 \\ &\vdots \\ \vec{a}_m &= (\vec{q}_1^T \cdot \vec{a}_m) \cdot \vec{q}_1 + (\vec{q}_2^T \cdot \vec{a}_m) \cdot \vec{q}_2 + \cdots + (\vec{q}_{m-1}^T \cdot \vec{a}_m) \cdot \vec{q}_{m-1} + ||\vec{u}_m|| \cdot \vec{q}_m\end{aligned}$$

Las combinaciones lineales de la derecha de cada vector columna \vec{a} son equivalentes a la multiplicación entre una matriz y las componentes de un vector:

$$\begin{aligned}\vec{a}_1 &= [\vec{q}_1] \cdot [||\vec{u}_1||] \\ \vec{a}_2 &= [\vec{q}_1 \quad \vec{q}_2] \cdot \begin{bmatrix} \vec{q}_1^T \cdot \vec{a}_2 \\ ||\vec{u}_2|| \end{bmatrix} \\ &\vdots \\ \vec{a}_m &= [\vec{q}_1 \quad \vec{q}_2 \quad \cdots \quad \vec{q}_{m-1} \quad \vec{q}_m] \cdot \begin{bmatrix} \vec{q}_1^T \cdot \vec{a}_m \\ \vec{q}_2^T \cdot \vec{a}_m \\ \vdots \\ \vec{q}_{m-1}^T \cdot \vec{a}_m \\ ||\vec{u}_m|| \end{bmatrix}\end{aligned}$$

Los vectores del lado derecho los denotaremos como \vec{r}_i , para cada $i = 1, 2, \dots, m$:

$$\vec{r}_1 = [||\vec{u}_1||] \quad \vec{r}_2 = \begin{bmatrix} \vec{q}_1^T \cdot \vec{a}_2 \\ ||\vec{u}_2|| \end{bmatrix} \quad \cdots \quad \vec{r}_m = \begin{bmatrix} \vec{q}_1^T \cdot \vec{a}_m \\ \vec{q}_2^T \cdot \vec{a}_m \\ \vdots \\ \vec{q}_{m-1}^T \cdot \vec{a}_m \\ ||\vec{u}_m|| \end{bmatrix}$$

Reemplazando en las ecuaciones de arriba:

$$\begin{aligned}\vec{a}_1 &= [\vec{q}_1] \cdot \vec{r}_1 \\ \vec{a}_2 &= [\vec{q}_1 \quad \vec{q}_2] \cdot \vec{r}_2 \\ &\vdots \\ \vec{a}_m &= [\vec{q}_1 \quad \vec{q}_2 \quad \cdots \quad \vec{q}_{m-1} \quad \vec{q}_m] \cdot \vec{r}_m\end{aligned}$$

Los vectores \vec{r}_i podemos considerarlos como las columnas de una matriz muy relevante que se denota como R :

$$R = [\vec{r}_1 \quad \vec{r}_2 \quad \cdots \quad \vec{r}_m]$$

La matriz R es relevante porque las combinaciones lineales del último conjunto de ecuaciones de arriba corresponden a la multiplicación entre Q y las columnas de R , que es lo mismo a calcular el producto QR y con ellas obtenemos a las columnas de A . Es decir, podemos

factorizar a esta última matriz como:

$$A = QR$$

y a esta ecuación se la conoce como **Descomposición** $A = QR$.

En general, si tenemos una **matriz** A de **columnas linealmente independientes** (i.e, de rango columna completo), es posible factorizarla como el producto entre Q , una matriz con las columnas ortonormalizadas de A ; y R , cuyas columnas contienen las constantes de las combinaciones lineales de Q .

4.1 Explicación de la Matriz R en $A = QR$.

La matriz R se caracteriza por ser **cuadrada**, **invertible** y **triangular superior**, donde:

$$R = \begin{bmatrix} \|\vec{u}_1\| & \vec{q}_1^T \cdot \vec{a}_2 & \cdots & \vec{q}_1^T \cdot \vec{a}_m \\ 0 & \|\vec{u}_2\| & \cdots & \vec{q}_2^T \cdot \vec{a}_m \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \|\vec{u}_m\| \end{bmatrix}$$

La diagonal principal de la matriz R está compuesta de las magnitudes de los vectores ortogonales \vec{u}_i , para $i = 1, 2, \dots, m$ y la parte inferior a ella solo consiste de **ceros**.

Ahora, recordemos que las columnas de Q son linealmente independientes al ser ortogonales, por lo tanto se cumple $Q^T Q = I$. En ese sentido, podemos obtener a la matriz R multiplicando a la ecuación $A = QR$ por Q^T :

$$\begin{aligned} A &= QR \\ Q^T A &= Q^T QR \\ Q^T A &= IR \\ Q^T A &= R \end{aligned}$$

Veamos que R será **cuadrada** porque Q y A son de igual dimensión. Si Q y A son de $n \times m$, entonces Q^T es de $m \times n$. Por lo tanto, $Q^T A = R$ será de $n \times n$.

Por otra parte, debido a que las columnas de A y de Q son linealmente independientes y a que $Q^T A$ conlleva a una matriz cuadrada, la matriz R siempre será **invertible**. Si lo evaluamos por su rango, será de **rango completo**.

Además, la multiplicación $Q^T A$ nos ayuda a entender por qué las entradas que están por debajo de **la diagonal de R son iguales a cero**.

$$Q^T A = R$$

$$\begin{bmatrix} \vec{q}_1^T \\ \vec{q}_2^T \\ \vdots \\ \vec{q}_m^T \end{bmatrix} \cdot \begin{bmatrix} \vec{a}_1 & \vec{a}_2 & \cdots & \vec{a}_m \end{bmatrix} = R$$

$$\begin{bmatrix} \vec{q}_1^T \cdot \vec{a}_1 & \vec{q}_1^T \cdot \vec{a}_2 & \cdots & \vec{q}_1^T \cdot \vec{a}_m \\ \vec{q}_2^T \cdot \vec{a}_1 & \vec{q}_2^T \cdot \vec{a}_2 & \cdots & \vec{q}_2^T \cdot \vec{a}_m \\ \vdots & \vdots & \ddots & \vdots \\ \vec{q}_m^T \cdot \vec{a}_1 & \vec{q}_m^T \cdot \vec{a}_2 & \cdots & \vec{q}_m^T \cdot \vec{a}_m \end{bmatrix}$$

Todos los productos punto que están debajo de la diagonal principal de R son entre **vectores ortogonales**. Por ejemplo, \vec{q}_2 es la versión ortonormal de \vec{u}_2 la que, a su vez, es ortogonal a \vec{a}_1 . Aquello explica por qué $\vec{q}_2^T \cdot \vec{a}_1 = 0$ y por el mismo motivo los demás productos puntos que están en esa zona, son iguales a ese valor.

4.2 Aplicación en el Método de Mínimos Cuadrados.

La descomposición $A = QR$ también podemos usarla para resolver las ecuaciones normales del método de mínimos cuadrados:

$$A^T A \hat{x} = A^T \vec{b}$$

Recordemos que el método de mínimos cuadrados trata con el problema de que en A de $n \times m$, $n > m$. Por lo tanto existe la posibilidad de que A sea de $\text{rango}(A) = m$. De ser el caso, podemos factorizarla como $A = QR$ y podemos reemplazar el producto QR en las ecuaciones normales:

$$(QR)^T \cdot QR \hat{x} = (QR)^T \vec{b}$$

$$(R^T Q^T QR) \hat{x} = R^T Q^T \vec{b}$$

$$R^T I R \hat{x} = R^T Q^T \vec{b}$$

$$R^T R \hat{x} = R^T Q^T \vec{b}$$

Las ecuaciones normales podemos trabajarlas de esa manera o es posible multiplicar esta ecuación por $(R^T)^{-1}$, ya que al ser R cuadrada e invertible, entonces su transpuesta también

tiene una inversa, donde $(R^T)^{-1} = (R^{-1})^T$.

$$((R^T)^{-1}R^T)R\hat{x} = ((R^T)^{-1}R^T)Q^T\vec{b}$$

$$IR\hat{x} = IQ^T\vec{b}$$

$$R\hat{x} = Q^T\vec{b}$$

No obstante, podemos ir más allá multiplicando a esta última por R^{-1} :

$$R^{-1}R\hat{x} = R^{-1}Q^T\vec{b}$$

$$I\hat{x} = R^{-1}Q^T\vec{b}$$

$$\hat{x} = R^{-1}Q^T\vec{b}$$

La principal ventaja de trabajar con $A = QR$, es que toma menos tiempo resolver las ecuaciones normales con R al ser triangular superior que al trabajar solo con $A^T A\hat{x} = A^T\vec{b}$.